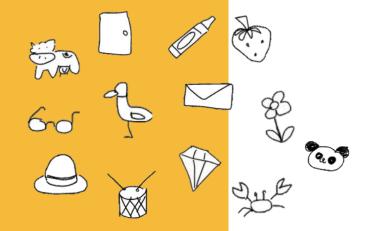
# 낙서에 기반한 그림 변환



1조 : 강민정, 유지민, 김채연, 정수현, 김서윤

#### **CONTENTS**



01. 선행연구



02. 데이터 전처리



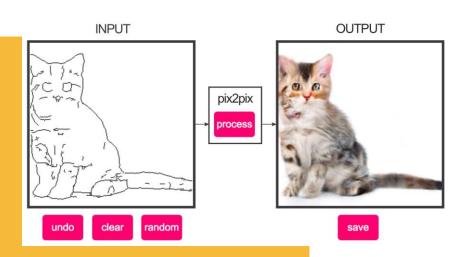
03. 모델링



04. 결과분석

# 기존 생성 모델

Pix2Pix: Image-to-Image Translation with CGAN





Canva, 'Text-to-Image'



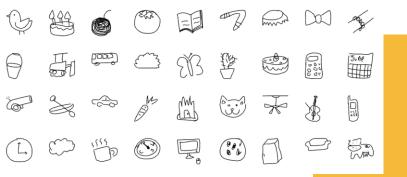
# 프로젝트 소개



사용자 중심의 간단한 입력



# 데이터셋 소개



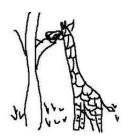
### **Quick, Draw!**

간결한 선으로 표현되어 있으며, 노이즈가 많다

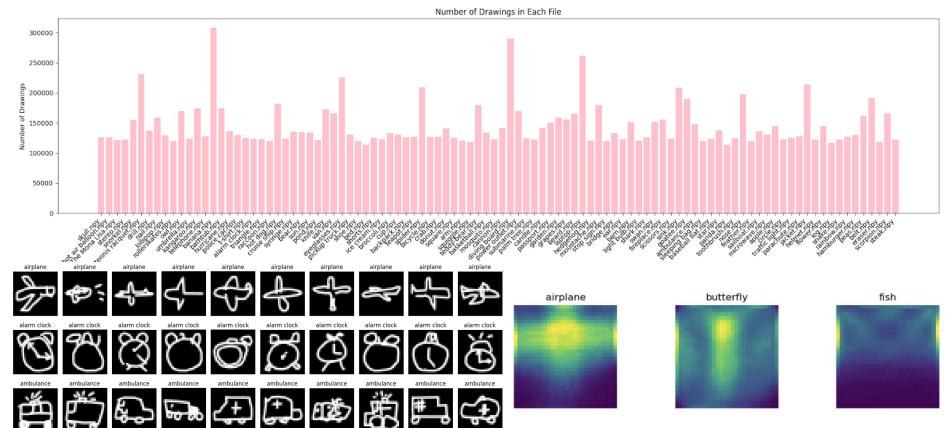
image (image)	text (string)
	"giraffe is eating leaves from the tree"
M.	"A zebra is eating grass"
Ťý.	" people are riding on the horses"
	"two girafee"s eating the tree leaves"
and the second	"An areoplane, airfranceis flying "

#### **Sketch-Scene**

비전문가들이 그린 스케치로, 정교함이 떨어진다

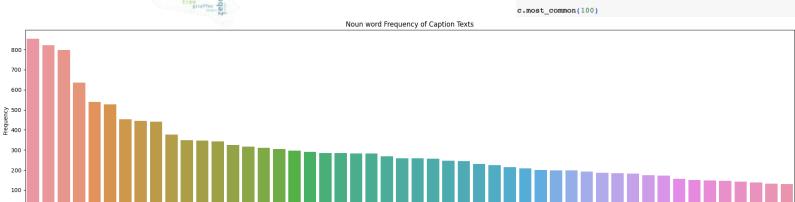


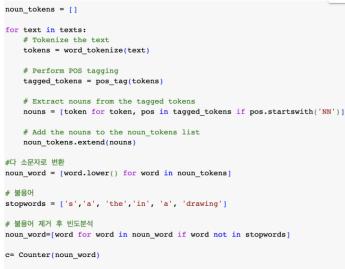
### **Quick Draw EDA**



### **Sketch-Scene EDA**











## 데이터 전처리

Resizing Shuffle augmentation

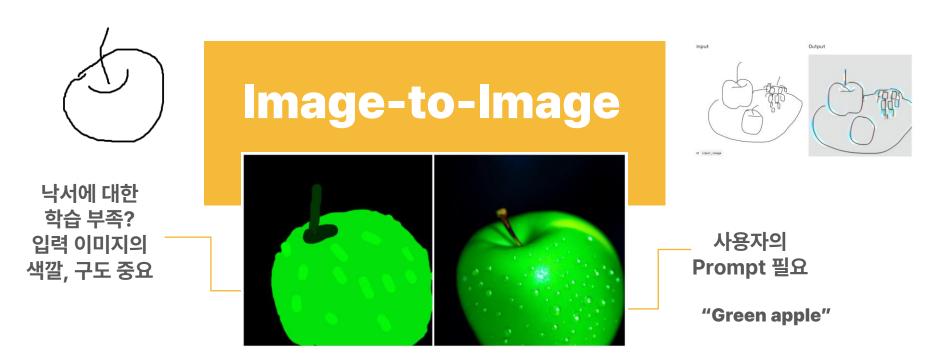
- □ Resizing
- □ 컬러 채널 복제
- □ 데이터 순서 섞기
- □ Augmentation
- □ "there is a {category }" 형태의 캡션

```
#이미지 확대 및 컬러 채널 복제 함수
def resize_and_replicate_channel(image):
   # 이미지 크기를 224x224로 리사이징
   img = Image.fromarray(image.reshape(28, 28))
   img_resized = img.resize((224, 224), Image.BILINEAR)
   # 컬러 채널 복제 (원본 이미지는 그레이스케일이므로 R, G, B 채널에 같은 값을 할당)
   img_rgb = Image.new("RGB", img_resized.size)
   img_rgb.paste(img_resized)
   return np.array(img_rgb)
# 데이터 생성기 설정
batch_size = 32 # 배치 크기
num_classes = len(class_names)
# 클래스별 이미지 데이터를 하나의 디렉토리로 합치기
all_resized_data = np.array([resize_and_replicate_channel(image) for class_name in class_
all labels = np.repeat(np.arange(num classes), 100)
# 미미지 데이터와 레이블의 소서를 섰기
random_indices = np.random.permutation(len(all_resized_data))
shuffled_data = all_resized_data[random_indices]
shuffled_labels = all_labels[random_indices]
# 데이터 생성기 생성
data_generator = ImageDataGenerator(
   preprocessing_function=preprocess_input,
   validation_split=0.2.
   rotation_range=20, # 무작위 회전
   width_shift_range=0.2, # 가로로 무작위 이동
   height_shift_range=0.2, # 세로로 무작위 이동
   shear_range=0.2. # 왜곡
   zoom_range=0.2. # 확대/축소
   horizontal_flip=True, # 수평 반전
   fill_mode='nearest' # 빈 공간 채우기
```



# **03** 모델링

## 모델링 – Task



### 모델링 – Task

### **Fine-Tuning**

- 낙서 데이터 학습 (sketch scene, quick draw)
- 적은 양의 데이터로도 적합한 결과 생성 가능
- 기존 모델의 성능 활용 가능

#### Point: 그림의 인식!

### Caption 생성

- Image Captioning을 통해 낙서를 자연어로 변환
- 자연어를 프롬프트로 이용해 다시 사진 생성 (사용자 입력 x)
- Image-to-Text + Text-to-Image

IMAGE TEXT IMAGE

# 모델링 – Image Captioning

#### Mobilenetv3small+ VGG 16

```
#모델 로드 및 컴파일
mobilenet = tf.keras.applications.MobileNetV3Small(
    input_shape=(224, 224, 3),
    include_top=False,
    weights='imagenet',
    pooling='avg'
)
mobilenet.trainable = False

x = mobilenet.output
x = Dense(128, activation='relu')(x)
output_layer = Dense(num_classes, activation='softmax')(x)

model = Model(inputs=mobilenet.input, outputs=output_layer)
model.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])
#모델 학습
epochs = 20 # 학습 에폭 수
model.fit(train_generator, epochs=epochs, validation_data=validation_generator)
```

- 특성 추출까지는 good
- 특성 기반 문장 생성 bad

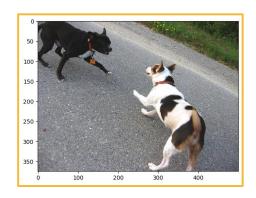
- 기본적인 모델의 파라미터 수 적음
- 낮은 성능

#### **Visual Attention**

```
class Captioner(tf.keras.Model):
 Oclassmethod
 def add method(cls. fun):
   setattr(cls. fun. name . fun)
   return fun
 def init (self, tokenizer, feature extractor, output layer, num layers=1,
              units=256, max length=50, num heads=1, dropout rate=0.1):
   super(), init ()
   self.feature extractor = feature extractor
   self.tokenizer = tokenizer
   self.word to index = tf.keras.layers.StringLookup(
       mask token="",
       vocabulary=tokenizer.get vocabulary())
   self.index to word = tf.keras.layers.StringLookup(
       mask token="",
       vocabulary=tokenizer.get vocabulary().
        invert=True)
   self.seq_embedding = SeqEmbedding(
       vocab size=tokenizer.vocabulary size().
       depth=units.
       max length=max length)
   self.decoder_layers = [
       DecoderLayer(units, num heads=num heads, dropout rate=dropout rate)
        for n in range(num_layers)]
   self.output layer = output layer
```

# 모델링 – Image Captioning

#### Mobilenetv3small+ VGG 16 - 결과



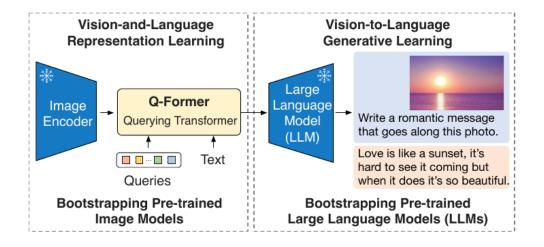
startseq two dogs play in the grass endseq



'startseg man is standing on top of mountain gazing at the sunset endseg'

#### => 그림에서 인식률 낮은 모습!

### BLIP-2

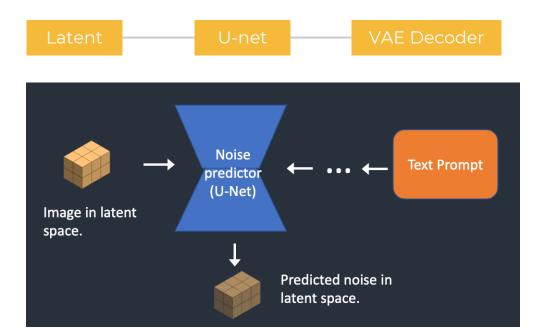


```
from transformers import AutoProcessor, Blip2ForConditionalGeneration

processor = AutoProcessor.from_pretrained("Salesforce/blip2-opt-2.7b")

model = Blip2ForConditionalGeneration.from_pretrained("ybelkada/blip2-opt-2.7b-fp16-sharded", device_map="auto", load_in_8bit=True)
```

# **Stable Diffusion**





#### **PEFT - LoRA**

### **BLIP-2 Finetuning**

```
[ ] from peft import LoraConfig, get_peft_model

# Let's define the LoraConfig
config = LoraConfig(
    r=16,
    lora_alpha=32,
    lora_dropout=0.05,
    bias="none",
    target_modules=["q_proj", "k_proj"]
)

model = get_peft_model(model, config)
model.print_trainable_parameters()
```

#### **PEFT (Parameter-Efficient Fine Tuning)**

- 적은 수의 파라미터를 학습하는 것만으로 모델 전체를 파인 튜닝 하는 것과 유사한 효과!
- 적은 데이터 체제 & 도메인 밖의 데이터 일반화 가능

#### LoRA (Low-Rank Adaptation of Large Language Models)

 "미리 학습된 모델 가중치를 고정하고, 각 트랜스포머 블록에 새로운 학습 가능한 레이어를 추가한다"

trainable params: 5,242,880 | all params: 3,749,922,816 | trainable%: 0.13981301102065136

### **Data Loader**

```
from torch.utils.data import Dataset, DataLoader, random_split
                                                                                                           # Loop through dataloader to print encodings
                                                                                                           for batch in train dataloader:
class ImageCaptioningDataset(Dataset):
                                                                                                               print (batch)
   def init (self, dataset, processor):
                                                                                                               break
       self.dataset = dataset
       self.processor = processor
                                                                                                           Image Size: torch.Size([1, 3, 224, 224])
                                                                                                           Data Type: torch.float32
   def __len__(self):
                                                                                                           Image Size: torch.Size([1, 3, 224, 224])
       return len(self.dataset)
                                                                                                           Data Type: torch.float32
                                                                                                           Image Size: torch.Size([1, 3, 224, 224])
   def getitem (self, idx):
                                                                                                           Data Type: torch.float32
       item = self.dataset[idx]
                                                                                                           Image Size: torch.Size([1, 3, 224, 224])
       encoding = self.processor(images=item["image"], padding="max length", return tensors="pt")
                                                                                                           Data Type: torch.float32
       # remove batch dimension
                                                                                                Key: pixel_values, Shape: torch.Size([50, 3, 224, 224])
       encoding = {k: v.squeeze() for k, v in encoding.items()}
                                                                                                Key: input_ids, Shape: torch.Size([50, 20])
       encoding["text"] = item["text"]
                                                                                                Key: attention_mask, Shape: torch.Size([50, 20])
       return encoding
```

train\_dataloader = DataLoader(train\_dataset, shuffle=True, batch\_size=batch\_size, collate\_fn=collate\_fn)
val\_dataloader = DataLoader(val\_dataset, batch\_size=batch\_size, collate\_fn=collate\_fn)

encoding = self.Processor : 이미지 전처리, 인코딩 padding = "max\_length" : 모델이 허용하는 최대 길이 패딩 squeeze() : 배치 차원 제거, [채널 수, 높이, 너비] 형태의 3차원 텐서 형성 이미지 크기 : 224 \* 224 텐서

### **Train & Eval**

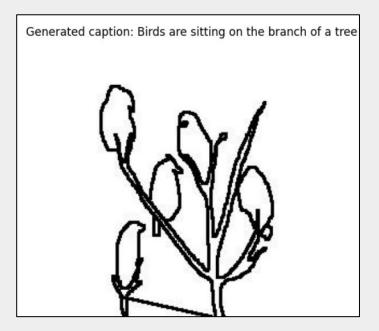
```
learning_rate = 5e-4
optimizer = torch.optim.Adam(model.parameters(), Ir=learning_rate)
```

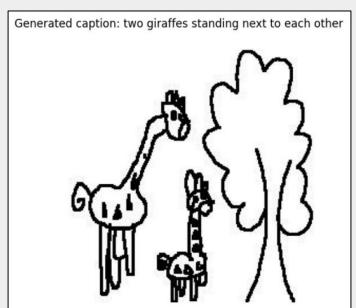
```
model.train() # 모델을 훈련 모드로 설정
for idx, batch in enumerate(train_dataloader):
   # 훈련 데이터 배치 가져오기
   input_ids = batch.pop("input_ids").to(device)
   pixel_values = batch.pop("pixel_values").to(device, torch.float16)
    labels = input ids
   optimizer.zero grad()
   outputs = model(input ids=input ids,
                   pixel values=pixel values.
                   labels=input ids)
    loss = outputs.loss
    loss.backward()
   optimizer.step()
   epoch train_loss += loss.item()
```

- input\_ids : 모델의 입력에 사용되는 텍스트 데이터
- pixel\_values : 모델의 입력에 사용되는 이미지 데이터
- labels : 정답 레이블 설정
- optimizer.step() : 파라미터들을 업데이트

# **Blip-2 Caption**

• 결과: 학습된 Blip-2 model로 생성된 캡션





### **Text to Image**

#### Stable Diffusion

```
import torch
from diffusers import StableDiffusionPipeline

# make sure you're logged in with `huggingface-cli login`
pipe = StableDiffusionPipeline.from_pretrained("CompVis/stable-diffusion-v1-4",
pipe = pipe.to("cuda")

Downloading (...)p16/model_index.json: 100%

text_encoder/model.safetensors not found
Fetching 16 files: 100%
543/543 [00:00<00:00, 16.3kB/s]

16/16 [00:30<00:00, 2.04s/it]
```

### • Trained blip-2를 활용해 생성된 caption 입력

```
new_image = pipe(generated_caption).images[0]

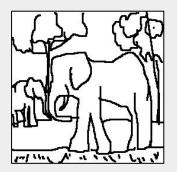
100% 50/50 [00:07<00:00, 7.11it/s]
```

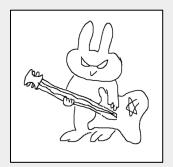
### **Text to Image**

'A photo of Elephants walking in the jungle'

Input & Output

a rabbit playing with a guitar



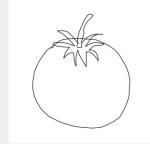


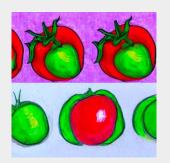






• Prompt text에 너무 의존하게 되면서 생기는 문제점?





### Img2Img

#### Stopwords 지정

a cartoon drawing of a man holding balloons

```
stopwords= ['drawn in', 'drawing', 'sketch', 'draw', 'doodle', 'a drawing', 'a doodle', 'on a white background', 'white background', 'drew']

import re
pattern = re.compile(r'\mu(?:' + '|'.join(map(re.escape, stopwords)) + r')\mub', re
prompt = "A photo of " + pattern.sub('', generated_caption).strip(); prompt

'A photo of Elephants walking in the jungle'
```

#### Trained blip-2를 활용해 생성된 caption

```
# prepare image for the model
inputs = processor(images=image, return_tensors="pt").to(device, torch.float16)
pixel_values = inputs.pixel_values

# Generate Caption -> using trained (finetuned) blip-2 model
generated_ids = model.generate(pixel_values=pixel_values, max_length=25)
generated_caption = processor.batch_decode(generated_ids, skip_special_tokens=True)[0]
print(generated_caption)
```

### Img2Img

#### Image to Image Import

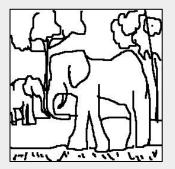
#### Output print (strength 조절)

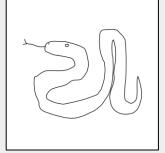
```
generator = torch.Generator(device=device).manual_seed(1024)
image = pipe(prompt=prompt, image=image_sketch, strength=0.95, guidance_scale= 10.5, generator=generator).images[0]
image

47/47 [00:02<00:00, 17.40it/s]</pre>
```

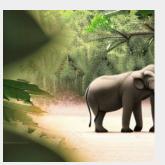
# lmg2lmg

### Input & Output











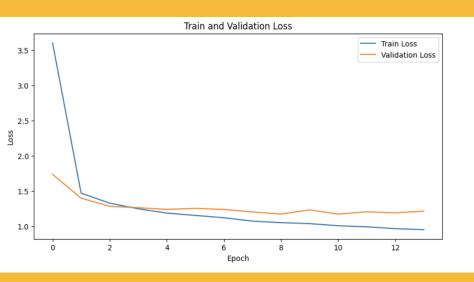


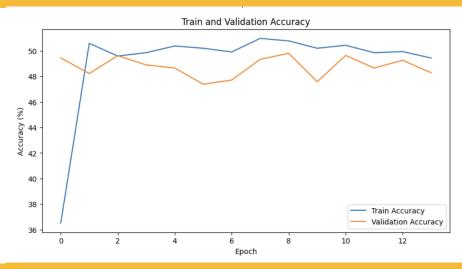
 04

 분석 및 개선점

# **Loss & Accuracy Plot**

Learning\_rate = 5e-4, dataset = 6000, batch\_size=60, epoch=15





# **Loss & Accuracy Plot**

- Dataset: 1000 ~ 6000
- Epoch: 10 ~ 20
- Batch Size : [16, 32, 60, 100] 등
- Learning Rate -> 5e-4에서 증가할 경우 제대로 수렴x, 감소할 경우 지나치게 느린 수렴
- Dropout (일부 뉴런 비활성화): 0.05

# 개선점



#### **Dataset**

Sketch-scene dataset

- 이미지당 캡션 하나씩 존재
- class 분류 X
- 양과 다양성 부족



#### **GPU**

모델의 복잡도

학습량의 한계

충분한 학습 부족

# 05 frontend

# Frontend 시현!

